

Maximal repetition & “Runs” conjecture

Riccardo Lo Iacono

Docente: Gabriele Fici

13 novembre 2024

1. Σ è un alfabeto ordinato e finito di simboli
2. Un elemento $S \in \Sigma^*$ è detto stringa, la cui lunghezza è denotata da $|S|$
3. Per ogni i , $1 \leq i \leq n = |S|$, $S[i]$ indica l' i -esimo carattere in S .
4. Per ogni i, j , $1 \leq i \leq j \leq n = |S|$, $S[i, j]$ indica la sottostringa compresa tra le posizioni i e j ,

Definizione: Data S una stringa, si definisce *periodo* un intero $p \geq 1$ tale che $S[i] = S[i + p]$, $\forall i = 1, \dots, |S| - p$

Definizione: Si definisce *esponente* \exp il rapporto tra la lunghezza di S e del suo più piccolo periodo.

Definizione: Una coppia (i, j) è detta ripetizione massimale (o run) di una stringa S , se $\text{exp}(S[i, j]) \geq 2p$ e la periodicità non può essere estesa né a destra né a sinistra.

Un esempio

Sia considerata la stringa $S = \text{babbabbababbabbabc}$; questa contiene nove run, mostrati in *Figura 1*.




Figura 1: Illustrazione dei run nella stringa $S = \text{babbabbababbabbabc}$.

Sia $\rho(S)$ il numero dei run in una stringa S .

Kolpakov e Kucherov¹ dimostrano che $\rho(S) = \mathcal{O}(|S|)$.

Congettura (Runs conjecture): $\rho(S) < |S|$ per ogni stringa S .

¹R. M. KUCHEROV AND G. KOLPAKOV, *Finding maximal repetitions in a word in linear time*. FOCS, 1999

1. Dimostrazione della runs conjecture.
2. Applicazione della soluzione algoritmica.

Sia \prec l'ordine totale definito su Σ , e si indichi con lo stesso l'ordine indotto su Σ^* .

Assunto \prec su Σ , si può definire $\tilde{\prec}$ l'ordine rovesciato. Ossia, un'ordine tale per cui presi $a, b \in \Sigma$, se

$$a \prec b \implies b \tilde{\prec} a$$

Siano \prec_0, \prec_1 rispettivamente l'ordine indotto su Σ^* e l'ordine rovesciato.

Data S una stringa e un indice i , $1 \leq i \leq n$, la stringa $S[i, n]S[1, i]$ è detta *shift ciclico* di S (se $i > 1$ *shift ciclico non banale*).

Definizione (Lyndon word): Una stringa $S \in \Sigma^*$, $S \neq \epsilon$, è detta Lyndon word se S è minore di ogni suo shift ciclico non banale.

La “Runs” conjecture

Congettura: $\rho(S) < |S|$, per ogni stringa S .

Dimostrazione: Sia S una stringa di lunghezza n , e sia (i, j) , $0 \leq i < j < n$, un suo run con periodo p minore.

Se $j + 1 < n$, ed inoltre $S[j - p + 1] \prec_0 S[j + 1]$, al run si assegna un indice k tale per cui $S[k, j]$ è il *longest proper suffix* di $S[i, j]$. Viceversa k definisce il più lungo suffisso per \prec_1 .

Si noti che se $k > i$ allora $k > 0$, e $S[k, j]$ contiene un intero periodo del run. Inoltre, $S[k, k + p - 1]$ è il più lungo coniugato di $S[i, i + p - 1]$ rispetto i due ordini. Ciò implica l'essere *border-free* che è una proprietà nota delle Lyndon word.

Si intende dunque dimostrare che ogni $k > 0$ è posizione iniziale di al più un solo *longest proper suffix* in un run.

Siano quindi considerati due run: (i, j) e (k, l) rispettivamente un p -run e un q -run. Inoltre, sia assunto per assurdo che i loro *longest proper suffix* condividano la stessa posizione iniziale k .

Poichè run distinti non possono avere uno stesso periodo si può assumere $p \neq q$.

1. $j = l$, ma allora $S[k, j] = S[k, l]$. Assumendo per esempio $p < q$, $S[k, k + q - 1]$ ha periodo p , ma allora questa non è border-free, che è una contraddizione.
2. sia $j < l$, ragionamento analogo vale nel caso $j > l$, inoltre siano i suffissi i più lunghi rispetto un stesso ordine. Posto $d = S[j + 1]$, carattere successivo il p -run, per definizione si ha $S[j - p + 1] \prec d$. Inoltre, $S[k, k - p + 1] \prec S[k, j - p]d$. Ma da ciò segue che $S[k, l - 1]$ non è massimale come supposto, poichè $S[i + p, j]$ è fattore del q -run.

3. $j \neq l$ e i suffissi risultano essere massimali secondo ordini diversi. Senza perdita di generalità sia $p < q$ e il suffisso del p -run sia massimale rispetto \prec_0 . Poichè $q > 1$, si hanno $S[k + q - 1] \prec_0 S[k]$ e $S[k + q - 1] \prec_1 S[k - 1]$, da cui $S[k - 1] \prec_0 S[k]$. Si ha però che $p \not\geq 1$ ($S[k] \prec_0 S[k - 1]$) e $p \neq 1$ ($S[k - 1] = S[k]$). Da cui un'altra contraddizione.

Ciò conclude la dimostrazione, mostrando come il numero di run non possa essere superiore agli $n - 1$ potenziali valori di k .